

Apunte 00 — El mapa del proyecto (léeme primero)

Proyecto Froth · aprender Machine Learning construyendo

1 Qué estamos construyendo y por qué

Froth es una herramienta que, dado un tema científico, descarga cientos de papers, los “entiende” por su contenido y dibuja un *mapa de subtemas*: burbujas de papers agrupados por significado, conexiones entre grupos, y zonas vacías (los *gaps* donde puedes aportar algo nuevo en tu tesis).

El proyecto tiene un doble objetivo, y los dos pesan igual:

1. **Aprender Machine Learning de verdad**, pieza a pieza, construyendo.
2. **Tener un producto útil** para literature reviews completos (no el clásico “5 papers que confirman lo que ya pensaba”).

Concepto: pipeline (tubería)

Todo el sistema es una **cadena de 5 pasos** donde la salida de uno es la entrada del siguiente:

[1] PULL → [2] EMBED → [3] REDUCE → [4] CLUSTER → [5] VISUALIZE

1. **Pull**: bajar papers (título, resumen, autores...) desde bases de datos públicas.
2. **Embed**: convertir cada resumen en un *vector* (lista de números que captura su significado).
3. **Reduce**: aplastar esos vectores de ~768 dimensiones a 2 para poder dibujarlos.
4. **Cluster**: agrupar los puntos cercanos = subtemas descubiertos automáticamente.
5. **Visualize**: burbujas, mapa mental, detección de gaps, borrador de review.

Cada paso es, a la vez, un concepto de ML que vas a dominar.

2 El mapa de carpetas (qué es cada cosa y en qué orden mirar)

Dentro de Documents\Master Thesis AI\ está todo. **Regla de oro**: las carpetas *con número* son tuyas (entra); las *sin número* son la maquinaria (no tocar). La chuleta completa está en el archivo 0_LEEME_PRIMERO.md de la raíz.

Tuyas (numeradas):

1. 1_Apuntes/ — **tu biblioteca** (estos PDFs). Léelos en orden: 00, 01, 02...
2. 2_Datos/ — los datos: **raw/** (crudos), **processed/** (tablas limpias), **embeddings/** (vectores). Se llena solo al correr el pipeline.
3. 3_Resultados/ — las salidas visibles: mapas, reviews.
4. 4_Notebooks/ — cuadernos de experimentación (Jupyter), cuando lleguen.
5. 5_Bitacoras/ — decisiones tomadas y tu diario de aprendizaje.

Maquinaria (sin número, no tocar):

- **froth/** — **el código fuente** (el motor). Un archivo por paso del pipeline: `config.py` (ajustes) → `pull.py` → `embed.py` → `cluster.py` → `graph.py` → `gaps.py` → `visualize.py`.
- **.venv/** — la burbuja con Python y sus librerías (ver Apunte 01).

- `tools/` — el compilador que convierte los apuntes en PDF.

Ojo / error típico

¿Por qué `froth/` **no** lleva número, si dijimos que todo debe estar ordenado? Porque Python importa el código por su nombre (`from froth import pull`) y un nombre que empiece por número rompe el lenguaje. El *orden* del pipeline no vive en el nombre de la carpeta sino dentro del código (`froth/__init__.py`). Los apuntes y tus carpetas, en cambio, sí van numerados porque nadie los importa: solo se leen.

3 Las 7 fases, de un vistazo

F0 Cimientos — entorno Python, Git, estructura. (*casi cerrada*)

F1 Pull — bajar 200–500 papers de un topic. (*primera versión ya funciona: 126 papers*)

F2 Embeddings — texto → vectores; buscador semántico. (*siguiente*)

F3 Clusters — las burbujas de subtemas (UMAP + HDBSCAN + BERTopic).

F4 Mapa mental — grafo de relaciones entre papers y temas.

F5 Gaps + borrador — zonas vacías del mapa y texto estructurado de review.

F6 Deep learning — PyTorch, transformers, afinar tu propio modelo.

4 Cómo usar estos apuntes

Cada vez que aparezca una habilidad o concepto nuevo en el proyecto, se genera un apunte PDF numerado que se guarda en `apuntes/`. Tú solo entras ahí y lees en orden. Cada apunte tiene cajas de colores: **Concepto** (la idea), **Pruébalo tú** (comandos para teclear tú mismo) y **Ojo** (errores típicos).

En una frase

Froth es una tubería de 5 pasos que convierte “un tema” en “un mapa de la literatura”; este apunte es tu plano general: carpetas, fases y orden de lectura.