

## Apunte 05 — Qué es un embedding (el corazón del proyecto)

Proyecto Froth · aprender Machine Learning construyendo

### 1 El problema: la computadora no entiende palabras

Tú, como experto, sabes que estas dos frases hablan de lo mismo:

- “*flotación de partículas finas*”
- “*recuperación de granos minerales pequeños mediante espuma*”

Pero no comparten casi ninguna palabra. Si buscáramos “coincidencia de palabras”, el sistema diría que no tienen nada que ver. Y al revés: “banco de peces” y “banco de dinero” comparten la palabra “banco” y no se parecen en nada.

**Conclusión:** contar palabras iguales no captura el *significado*. Necesitamos otra cosa.


### 2 La solución: convertir el texto en un punto en un mapa

Concepto: embedding (vector de significado)

Un **embedding** es un texto convertido en una lista de números —sus *coordenadas*— de modo que se puede colocar como un **punto** en un “mapa del significado”. La lista de números también se llama **vector**.

La propiedad mágica: el mapa está construido para que **textos con significado parecido queden cerca**, y los distintos, lejos. Dos papers que estudian lo mismo caen juntos aunque usen palabras diferentes.

Imagina el mapa de significado de tus papers (aquí en 2D para poder dibujarlo):



Cada punto es un paper. Los de flotación se agrupan a la izquierda; los de by-products, a la derecha; y el paper off-topic que se coló (¿recuerdas el de telecomunicaciones?) queda *solo, lejos de todo* — por eso luego el sistema podrá apartarlo automáticamente.

### 3 ¿Por qué 768 coordenadas y no 2?

#### Concepto: dimensiones

En un mapa de verdad usas **2** coordenadas: latitud y longitud. Pero el significado es mucho más rico que una posición en un plano, así que hace falta más “espacio”. El modelo que usaremos (SPECTER) describe cada texto con **~768 coordenadas**.

No lo puedes dibujar (nadie ve en 768 dimensiones), pero eso no importa: las **matemáticas** sí saben medir qué tan cerca están dos puntos aunque tengan 768 coordenadas. En el Apunte 06 veremos cómo (la “similitud coseno”). En la Fase 3 aplastaremos esas 768 a 2 justo para poder dibujar el mapa de verdad.

Cada uno de esos 768 números captura algún “aspecto” abstracto del texto. No son interpretables uno a uno (el número 348 no significa “cuánto habla de litio”); lo que importa es el *patrón completo* de los 768 juntos.

### 4 ¿De dónde salen los números? Un modelo preentrenado

#### Concepto: modelo preentrenado

Los 768 números los produce **SPECTER**: una *red neuronal* que la organización AllenAI ya entrenó leyendo millones de papers científicos (y quién cita a quién). Aprendió a colocar textos parecidos cerca.

Lo clave: nosotros **no entrenamos nada**. Descargamos el modelo ya hecho y lo usamos, como quien usa una calculadora sin fabricarla. Eso es un *modelo preentrenado*, y es la forma más rápida y potente de empezar en ML de texto.

#### Ojo / error típico

¿Por qué SPECTER y no un modelo genérico? Porque está entrenado **con papers**. Un modelo generalista entiende texto común; SPECTER entiende el lenguaje académico (métodos, resultados, jerga científica) mucho mejor para nuestro caso. Herramienta especializada para un trabajo especializado.

### 5 Qué haremos con esto (lo que viene)

1. Instalar las librerías que cargan SPECTER (siguiente paso).
2. Convertir tus 126 abstracts en 126 vectores (una matriz  $126 \times 768$ ).
3. Medir parecidos con la similitud coseno (Apunte 06).
4. Construir el **buscador semántico**: escribes una frase  $\rightarrow$  te da los 5 papers más parecidos por significado. (El momento “wow”).

#### En una frase

Un embedding convierte cada texto en un punto (768 coordenadas) dentro de un “mapa del significado” donde lo parecido queda cerca; esos números los da SPECTER, un modelo ya entrenado con papers que nosotros solo reutilizamos.