

Apunte 05 — Qué es un embedding (el corazón del proyecto)

Proyecto Froth · aprender Machine Learning construyendo

1 El problema: la computadora no entiende palabras

Tú, como experto, sabes que estas dos frases hablan de lo mismo:

- “*flotación de partículas finas*”
- “*recuperación de granos minerales pequeños mediante espuma*”

Pero no comparten casi ninguna palabra. Si buscáramos “coincidencia de palabras”, el sistema diría que no tienen nada que ver. Y al revés: “banco de peces” y “banco de dinero” comparten la palabra “banco” y no se parecen en nada.

Conclusión: contar palabras iguales no captura el *significado*. Necesitamos otra cosa.


2 La solución: convertir el texto en un punto en un mapa

Concepto: embedding (vector de significado)

Un **embedding** es un texto convertido en una lista de números —sus *coordenadas*— de modo que se puede colocar como un **punto** en un “mapa del significado”. La lista de números también se llama **vector**.

La propiedad mágica: el mapa está construido para que **textos con significado parecido queden cerca**, y los distintos, lejos. Dos papers que estudian lo mismo caen juntos aunque usen palabras diferentes.

Imagina el mapa de significado de tus papers (aquí en 2D para poder dibujarlo):



Cada punto es un paper. Los de flotación se agrupan a la izquierda; los de by-products, a la derecha; y el paper off-topic que se coló (¿recuerdas el de telecomunicaciones?) queda *solo, lejos de todo* — por eso luego el sistema podrá apartarlo automáticamente.

3 ¿Por qué 768 coordenadas y no 2?

Concepto: dimensiones

En un mapa de verdad usas **2** coordenadas: latitud y longitud. Pero el significado es mucho más rico que una posición en un plano, así que hace falta más “espacio”. El modelo que usaremos (SPECTER) describe cada texto con **~768 coordenadas**.

No lo puedes dibujar (nadie ve en 768 dimensiones), pero eso no importa: las **matemáticas** sí saben medir qué tan cerca están dos puntos aunque tengan 768 coordenadas. En el Apunte 06 veremos cómo (la “similitud coseno”). En la Fase 3 aplastaremos esas 768 a 2 justo para poder dibujar el mapa de verdad.

Cada uno de esos 768 números captura algún “aspecto” abstracto del texto. No son interpretables uno a uno (el número 348 no significa “cuánto habla de litio”); lo que importa es el *patrón completo* de los 768 juntos.

4 ¿De dónde salen los números? Un modelo preentrenado

Concepto: modelo preentrenado

Los 768 números los produce **SPECTER**: una *red neuronal* que la organización AllenAI ya entrenó leyendo millones de papers científicos (y quién cita a quién). Aprendió a colocar textos parecidos cerca.

Lo clave: nosotros **no entrenamos nada**. Descargamos el modelo ya hecho y lo usamos, como quien usa una calculadora sin fabricarla. Eso es un *modelo preentrenado*, y es la forma más rápida y potente de empezar en ML de texto.

Ojo / error típico

¿Por qué SPECTER y no un modelo genérico? Porque está entrenado **con papers**. Un modelo generalista entiende texto común; SPECTER entiende el lenguaje académico (métodos, resultados, jerga científica) mucho mejor para nuestro caso. Herramienta especializada para un trabajo especializado.

5 Qué haremos con esto (lo que viene)

1. Instalar las librerías que cargan SPECTER (siguiente paso).
2. Convertir tus 126 abstracts en 126 vectores (una matriz 126×768).
3. Medir parecidos con la similitud coseno (Apunte 06).
4. Construir el **buscador semántico**: escribes una frase → te da los 5 papers más parecidos por significado. (El momento “wow”).

En una frase

Un embedding convierte cada texto en un punto (768 coordenadas) dentro de un “mapa del significado” donde lo parecido queda cerca; esos números los da SPECTER, un modelo ya entrenado con papers que nosotros solo reutilizamos.