

Apunte 08 — Similitud coseno: medir qué tan parecidos son dos papers


Proyecto Froth · aprender Machine Learning construyendo

1 El problema

Ya tienes 126 puntos (vectores) en el mapa del significado. Pregunta natural: dados dos papers, ¿cómo pone la computadora un número a “qué tan parecidos son”? Con la **similitud coseno**.

2 La idea: el ángulo entre dos flechas

Cada vector es una **flecha** que sale del origen y apunta hacia la posición del paper. Para comparar dos papers miramos el **ángulo** entre sus flechas:



Concepto: similitud coseno

Es el **coseno del ángulo** entre dos vectores. Da un número fácil de leer:

- Flechas casi alineadas (ángulo pequeño) → coseno **cercano a 1** → mismo tema.
- Flechas perpendiculares (90°) → coseno **cercano a 0** → sin relación.

Para embeddings de texto el valor suele caer entre 0 y 1.

Ojo / error típico

¿Por qué el *ángulo* y no la *distancia* entre las puntas? Porque lo que importa es **hacia dónde apunta** el significado, no qué tan larga es la flecha. Dos papers del mismo tema, uno con abstract largo y otro corto, tendrán flechas de distinto “tamaño” pero apuntando al mismo lado: el ángulo los reconoce como iguales; la distancia recta se dejaría engañar por el tamaño.

3 La prueba con tus papers (números reales)

Tomamos el paper “*Enrichment of Lepidolite via Flotation*” y calculamos su coseno contra los otros 125. Esto salió:

Coseno	Paper	¿Tiene sentido?
0.942	Selective Inhibition ... Flotation of Lepidolite	sí: mismo tema
0.941	Froth Flotation of Lepidolite — A Review	sí: mismo tema
0.932	Flotation Collectors for Lepidolite Mineral	sí: mismo tema
0.511	...Radio Resources for Multicell Mobile	no: telecomunicaciones
0.507	Adrienne Rich and the Poetry...	no: poesía
0.495	Theodore Beza... Peace in France 1572	no: historia

Los papers de flotación de lepidolita salieron con coseno ~ 0.94 (casi idénticos en tema), y el ruido off-topic que se coló en la Fase 1 quedó en ~ 0.50 (lejos). El sistema los ordenó bien **sin saber nada de minería**: solo por el significado de los abstracts.

Concepto: la herramienta: `cosine_similarity` de scikit-learn

No calculamos el ángulo a mano. `sklearn.metrics.pairwise.cosine_similarity` toma vectores y devuelve los cosenos. Le pasamos un paper contra la matriz de los 126 y obtuvimos las 126 similitudes de un golpe.

4 Para qué sirve esto

Este número es el ladrillo del **buscador semántico** (paso siguiente): para encontrar los papers más parecidos a una frase, la convertimos en vector y nos quedamos con los de *mayor* coseno. Y en la Fase 3, la misma idea de “quién está cerca de quién” es la que forma las burbujas de subtemas.

En una frase

La similitud coseno mide el ángulo entre dos vectores: ≈ 1 mismo tema, ≈ 0 sin relación. Con tus papers, flotación-vs-flotación dio 0.94 y flotación-vs-ruido 0.50: funciona.