

Apunte 09 — El buscador semántico (juntamos todo)

Proyecto Froth · aprender Machine Learning construyendo

1 Qué construimos

Una herramienta que recibe una **frase en lenguaje natural** y devuelve los papers más parecidos *por significado* — no por palabras compartidas. Es la función `most_similar()` de `froth/embed.py`, y une todo lo aprendido en la Fase 2.

Concepto: búsqueda semántica vs. búsqueda por palabras

La búsqueda clásica (Ctrl+F, Google básico) empareja **palabras**: si buscas “grain size” no encuentra un texto que diga “coarse and fine particles”, aunque signifiquen lo mismo. La búsqueda **semántica** empareja **significado**: convierte tu frase en un vector y busca los vectores cercanos, así que sí los relaciona.

2 Cómo funciona por dentro (3 pasos)

1. **Vectorizar la frase.** Se pasa tu frase por el *mismo* modelo (SPECTER) con `model.encode([query])`. Clave: la frase y los papers deben vivir en el mismo mapa, o comparar no tendría sentido.
2. **Medir contra todos.** Con `cosine_similarity` calculamos el coseno de tu frase contra los 126 vectores de golpe.
3. **Quedarnos con los mejores.** Ordenamos de mayor a menor coseno y devolvemos los `k` primeros (por defecto 5), como una tabla `score`, `title`, `year`.

Ojo / error típico

El mismo modelo para las dos cosas. Si vectorizaras los papers con SPECTER y la frase con otro modelo distinto, los dos “mapas” no coincidirían y los resultados serían basura. Consistencia del embedding = regla de oro.

3 La prueba (resultados reales)

Búsqueda: “*how does grain size affect the recovery of minerals by froth flotation*”

Score	Paper
0.873	Role of Bubble Size in Flotation of Coarse and Fine Particles
0.856	Effect of Clay Slime on the Froth Stability and Flotation Performance
0.855	Spodumene Flotation Mechanism

Escribimos “grain size” y encontró papers de “coarse and fine particles” y “ultrafine”: **entendió el significado, no las palabras**.

Búsqueda: “*extracting beryllium and tantalum as valuable by-products*”

Score	Paper
0.812	Niobium and tantalum
0.740	Concentration of Tantalum and Niobium

Trajo justo los papers de los by-products Ta/Nb/Be de tu tesis.

Concepto: score entre 0 y 1

El **score** es la similitud coseno (Apunte 08). Aquí ronda 0.7–0.9: alto, tiene sentido. Ojo: los scores de “frase libre vs. paper” suelen ser algo más bajos que “paper vs. paper” (0.94 antes), porque una frase corta es menos rica que un abstract entero. Lo que importa es el *orden*, no el número absoluto.

4 Qué significa esto para el proyecto

Ya tienes una herramienta útil de verdad: interrogar tu corpus en lenguaje natural. Y más importante: la maquinaria (vectorizar + coseno + ordenar) es **la misma** que en la Fase 3 formará las burbujas de subtemas. Dominar esto es dominar el núcleo de Froth.

En una frase

El buscador semántico convierte tu frase en vector, la compara por coseno contra los 126 papers y devuelve los más parecidos por significado. Probado: “grain size” encontró “fine/coarse particles”. El motor de Froth ya late.