

Apunte 12 — Reducción de dimensiones: de 768 a 2 sin perder el vecindario

Proyecto Froth · aprender Machine Learning construyendo


1 El problema

Cada paper es un punto en **768 dimensiones** (Apuntes 05–07). Tu pantalla tiene **2**. Para dibujar el mapa hay que “aplastar” — pero un mal aplastado encima puntos que no tienen nada que ver, y el mapa engaña. La pregunta de este apunte: *¿cómo se aplasta conservando quién está cerca de quién?*

2 La intuición clásica: PCA y las sombras

Concepto: PCA (análisis de componentes principales)

Piensa en la **sombra** de tu mano en la pared: un objeto 3D proyectado en 2D. Si orientas bien la mano, la sombra conserva la forma (se ven los dedos); si la orientas mal, todo se encima. **PCA busca el “ángulo de luz” que menos información pierde:** las direcciones en las que los datos más varían. Es la técnica clásica, rápida y muy usada.



Limitación: PCA solo hace proyecciones *rectas* (lineales). Si los datos forman nubes curvas o enredadas —como suele pasar con texto—, hasta el mejor ángulo encima cosas.

3 La moderna: UMAP y la mudanza de vecindarios

Concepto: UMAP

UMAP no proyecta sombras. Trabaja en dos tiempos:

1. En 768D, apunta para cada paper **quiénes son sus vecinos más cercanos**.
2. Coloca los puntos en 2D doblando y estirando lo que haga falta, con una sola obsesión: **que cada punto conserve a sus vecinos al lado**.

Como mudar una ciudad a un mapa más pequeño garantizando que cada casa siga junto a las mismas casas de antes, aunque las distancias largas cambien. Por eso UMAP separa nubes que PCA encima: no está limitado a proyecciones rectas.

4 La letra pequeña: todo mapa 2D miente un poco

Ojo / error típico

Al aplastar 768 dimensiones a 2 **siempre** se pierde algo. En un mapa UMAP:

- **Confía en:** quién está pegado a quién; las nubes/grupos que se forman.
- **NO confíes en:** las distancias largas (“este cluster está al doble de distancia que aquel”) ni en el tamaño aparente de las nubes.
- Los ejes X e Y **no significan nada** (no son “más flotación” o “más litio”); son solo el resultado del acomodo. Por eso los mapas UMAP se publican sin números en los ejes.

Saber esto te pone por delante de mucha gente que interpreta estos mapas de más.

5 Cómo lo usaremos (lo que viene)

1. Instalar `umap-learn` (si Python 3.14 lo permite; hay plan B con PCA/t-SNE de scikit-learn — cambia la pieza, no el concepto).
2. Correr UMAP sobre la matriz $126 \times 768 \rightarrow$ tabla de 126 puntos (x, y).
3. Dibujar el primer scatter: tu primer vistazo al mapa (Apunte 13).
4. Después, agrupar las nubes en subtemas con HDBSCAN (Apunte 14).

En una frase

PCA aplasta buscando el mejor “ángulo de sombra” (rápido pero recto); UMAP reacomoda preservando los vecindarios (ideal para texto). En el mapa resultante: confía en los vecinos y las nubes, desconfía de distancias largas, y los ejes no significan nada.