

Apunte 13 — UMAP en acción: el primer mapa de tus 126 papers

Proyecto Froth · aprender Machine Learning construyendo

1 Qué hicimos

Corrimos UMAP de verdad sobre la matriz 126×768 y salió una tabla 126×2 : una coordenada (x, y) por paper. Las guardamos en `2_Datos/embeddings/umap_2d.npy` y dibujamos el primer scatter (está en `3_Resultados/umap_first_look.png`).

Lo importante del resultado: sin decirle nada sobre minería, ya se ven *estructuras*: una nube grande a la izquierda, un brazo arriba a la derecha, una franja diagonal abajo con un grumo apretado en la esquina. Eso son (probablemente) tus subtemas esperando nombre. El paso siguiente (HDBSCAN) los delimitará formalmente.

2 Las tres decisiones del código (y por qué)

Concepto: `metric="cosine"` — medir con la misma vara

UMAP necesita decidir quiénes son los “vecinos” de cada punto, y para eso mide distancias. Le dijimos que las mida con **similitud coseno** — exactamente la misma vara de la Fase 2 (Apunte 08). Si la Fase 2 compara papers por coseno y UMAP usara otra medida, el mapa contaría una historia diferente a la del buscador. Consistencia ante todo.

Concepto: `random_state=42` — reproducibilidad

UMAP tiene azar interno (de dónde parte el acomodo). Sin semilla fija, cada corrida daría un mapa *ligeramente* distinto — mismos grupos, otras posiciones. Fijar `random_state=42` hace que cualquiera que corra tu código obtenga **el mismo mapa**. En ciencia (y en tu tesis) eso se llama *reproducibilidad* y es sagrado. (El 42 es una broma-tradición de programadores; cualquier número fijo sirve.)

Concepto: `n_components=2` — cuántas dimensiones de salida

Le pedimos 2 dimensiones porque el objetivo es *dibujar*. Se puede reducir a 5 o 10 (útil a veces para el clustering); lo exploraremos si hace falta.

Ojo / error típico

En el scatter quitamos los números de los ejes **a propósito**. Tras el Apunte 12 ya sabes por qué: en UMAP los ejes no significan nada. Si algún día ves un mapa UMAP con ejes numerados e interpretados (“a mayor X, mayor tal cosa”), desconfía del autor.

3 Cómo leer tu primer mapa

- **Nubes densas** = grupos de papers que hablan de lo mismo (futuros clusters).

- **Puntos sueltos / puentes** = papers que mezclan temas o que no encajan (candidatos a “ruido” en HDBSCAN).
- **Forma general** (brazo, franja, grumo): sugiere subtemas con distinta cohesión — un grumo apretado es un tema muy específico; una nube amplia, un tema general.

En una frase

UMAP convirtió 768 dimensiones en un mapa 2D reproducible (semilla fija) midiendo vecinos con coseno (la misma vara de siempre), y las nubes aparecieron solas: son los subtemas que HDBSCAN delimitará en el siguiente paso.