

Apunte 14 — Clustering: que el algoritmo encuentre los grupos (HDBSCAN)

Proyecto Froth · aprender Machine Learning construyendo

1 El problema

Tu mapa 2D (Apunte 13) muestra nubes a simple vista, pero “a simple vista” no es un método: necesitamos que un algoritmo delimite los grupos de forma objetiva y repetible. Eso es **clustering no supervisado**: agrupar sin que nadie diga qué es cada grupo ni cuántos hay.

2 La intuición clásica: K-means (y sus dos trampas)

Concepto: K-means

El método más famoso. Le dices “quiero **K** grupos” y él reparte los puntos en K grupos compactos. Simple y rápido, pero con dos trampas para nuestro caso:

1. **Tienes que adivinar K.** ¿Cuántos subtemas tiene tu topic? Justo eso es lo que NO sabemos (es lo que queremos descubrir).
2. **Obliga a TODOS los puntos a entrar en algún grupo.** El paper de poesía acabaría asignado a un cluster de flotación, contaminándolo.

3 La práctica: HDBSCAN, clustering por densidad

Concepto: HDBSCAN

En vez de repartir, HDBSCAN busca **zonas densas**: regiones donde hay muchos puntos apretados. Cada zona densa = un cluster. Consecuencias:

- **Decide solo cuántos grupos hay** (nosotros no adivinamos K).
- Lo que no pertenece a ninguna zona densa queda como **ruido** (etiqueta -1), en vez de contaminar un grupo.
- Su parámetro principal es `min_cluster_size`: cuántos puntos mínimo hacen falta para que algo cuente como grupo (en Froth: `MIN_CLUSTER_SIZE = 8`).

4 Lo que pasó con TUS papers (la historia real)

Con `min_cluster_size=8`, HDBSCAN encontró **3 clusters + 9 papers de ruido** (y con 5, casi idéntico: resultado *estable*, buena señal):

Grupo	Tamaño	Qué resultó ser (Apunte 15)
Cluster 0	49	Geología de pegmatitas y granitos de metales raros
Cluster 2	43	Flotación de lepidolita (el corazón de la tesis)
Cluster 1	25	“Cajón de lo ajeno”: reciclaje/economía del litio + los off-topic
Ruido	9	Puentes generalistas y rarezas

Ojo / error típico

Dos sorpresas que enseñan mucho:

1. **“Ruido” no siempre es basura.** En el ruido cayeron dos clásicos totalmente on-topic (p.ej. *The Effect of Bubble Size on Fine Particle Flotation*, 527 citas). ¿Por qué? Son papers *generalistas* que hablan con varios subtemas a la vez: viven “entre” las nubes, sin pertenecer del todo a ninguna.
2. **Los off-topic no fueron ruido: fueron puestos en cuarentena juntos.** El paper de telecomunicaciones, el de poesía y el de historia cayeron los tres dentro del cluster 1. “No ser del tema” también es algo en común, y forma su propia nube lejos de las nubes mineras.

En una frase

K-means exige adivinar K y fuerza a todos adentro; HDBSCAN agrupa por densidad, decide solo cuántos grupos hay y aparta el ruido. En tus datos: 3 subtemas estables + 9 ruidos, con los off-topic en cuarentena dentro de su propio cluster.