

Apunte 15 — Ponerle nombre a las burbujas: c-TF-IDF

Proyecto Froth · aprender Machine Learning construyendo

1 El problema

HDBSCAN te da grupos llamados “0”, “1”, “2”. Para el mapa necesitamos nombres con significado. ¿Cómo se nombra un grupo de 49 papers *automáticamente*?

2 Por qué NO sirven las palabras más frecuentes

Si tomas las palabras más repetidas de cada cluster, en TODOS sale lo mismo: “mineral”, “flotation”, “study”, “results”. Frecuente $\neq$ característico. Lo que distingue a un grupo son las palabras que él usa mucho **y los demás poco**.

Concepto: TF-IDF y su versión por clases (c-TF-IDF)

TF-IDF puntúa cada palabra combinando dos factores: qué tan frecuente es en un documento (TF) y qué tan *rara* es en el resto (IDF). Palabra frecuente aquí + rara en los demás = puntuación alta = característica.

La variante **c-TF-IDF** (class-based) aplica esto a clusters: se pegan todos los abstracts de cada cluster como si fueran **un solo mega-documento**, y se comparan los mega-documentos entre sí. Las palabras top de cada mega-documento son la etiqueta del cluster. Es el mismo truco que usa BERTopic por dentro.

3 Lo que salió con TUS clusters

Grupo	Keywords (top c-TF-IDF)	Lectura
Cluster 0 (49)	melt, crystallization, Nb, Zr, Hf	Geología/petrología de pegmatitas y granitos de metales raros
Cluster 2 (43)	flotation, collector, froth, lepidolite	Flotación de lepidolita: colectores y espumas
Cluster 1 (25)	commodity, old scrap, USGS, women, men	Economía/reciclaje del litio + los papers off-topic (cuarcentena)

El mapa tiene sentido mineralógico completo: a un lado la geología del yacimiento, al otro el procesamiento (flotación), y aparte “el resto del mundo”.

Ojo / error típico

Hallazgo de calidad de datos: entre las keywords del cluster de flotación se colaron palabras en *francés* (“du”, “récupération”). Causa: el corpus tiene abstracts en francés (¡Beauvoir está en Francia!) y nuestra lista de *stopwords* (palabras vacías que se ignoran: the, of, and...) solo cubre inglés. No rompe nada, pero ensucia etiquetas. Arreglos posibles: stopwords multilingües o detectar idioma en la limpieza de Fase 1. Lección: los datos reales siempre traen una sorpresa más.

Concepto: el algoritmo propone, el experto valida

Las etiquetas automáticas son un *borrador*: “melt-crystallization-Nb” es útil, pero tú como experto la refinarás a “Petrogénesis de granitos de metales raros”. Esa división de trabajo (máquina propone, humano cura) es exactamente cómo se usan estas herramientas en investigación seria.

En una frase

c-TF-IDF nombra cada cluster con sus palabras características (frecuentes dentro, raras fuera), pegando cada cluster en un mega-documento. Tus 3 subtemas: geología de pegmatitas, flotación de lepidolita, y economía/reciclaje (con los off-topic en cuarentena).