

Apunte 16 — El bubble map interactivo (Plotly) y el truco del slider

Proyecto Froth · aprender Machine Learning construyendo

1 Qué construimos

El entregable estrella de la Fase 3: el **mapa de burbujas interactivo** de tus 126 papers. Existe en dos formas, alimentadas por el mismo código:

1. `3_Resultados/topic_map.html` — archivo autocontenido: doble clic y se abre en cualquier navegador, sin servidor. Compartible.
2. La pestaña **Topic map** de tu web app (`app.py`), con controles en vivo.

Qué se ve: un punto por paper, un color por subtema (geología azul, flotación verde, economía/ajeno naranja, ruido gris), tamaño = citas, la etiqueta de cada subtema flotando sobre su nube, y al pasar el mouse: título, autores, año, citas.

Concepto: Plotly

Librería de gráficos **interactivos**: en vez de una imagen fija (matplotlib), produce HTML+JavaScript con zoom, pan, tooltips y leyenda clicable “gratis”. Por eso el mapa se puede guardar como archivo y abrirse en cualquier lado: el navegador hace el trabajo.

Concepto: una figura, dos caras (arquitectura)

La función `bubble_figure()` en `froth/visualize.py` construye la figura, y DOS clientes la reutilizan: `plot_bubbles()` la guarda como HTML, y `app.py` la muestra en Streamlit. Si mañana mejoras el mapa, mejora en los dos sitios a la vez. Principio general: *el motor no se duplica; se envuelve*.

2 El truco del slider de granularidad

La web app tiene un slider “min papers per subtopic” que re-agrupa el mapa **al instante**. ¿Cómo puede ser tan rápido, si el pipeline tarda?

Concepto: separar lo lento de lo rápido

El pipeline tiene dos partes muy distintas:

- **Lenta**: UMAP (acomodar 126 puntos desde 768D). Se calcula UNA vez y se cachea.
- **Rápida**: HDBSCAN sobre los puntos 2D ya acomodados (milisegundos) + re-etiquetar.

La clave: la granularidad **no afecta a UMAP**, solo a HDBSCAN. Así que mover el slider solo repite la parte barata. Identificar qué se puede cachear y qué debe recalcularse es una habilidad central de ingeniería de datos — la acabas de usar.

Ojo / error típico

La granularidad es una **decisión de lectura**, no una verdad: con valor bajo verás muchos subtemas pequeños (más detalle, más fragmentación); con valor alto, pocos grandes (más síntesis). No existe “el número correcto de clusters” — existe el que mejor cuenta la historia para tu propósito. Por eso es un slider tuyo y no una constante escondida.

3 Dónde estamos frente a la competencia

Con este mapa alcanzamos la **paridad** visual/interactiva (hover, zoom, filtros, tamaño por citas) con Connected Papers, Litmaps o VOSviewer. Y ya tenemos diferenciadores que ellos no: mapa por *contenido* (no citas), subtemas auto-nombrados, granularidad en vivo, ruido separable, búsqueda semántica integrada y todo open-source. Los diferenciadores estrella (gaps + borrador de review + módulo tarea/PDFs) llegan en las Fases 4–5. La tabla completa vive en `CLAUDE.md`.

En una frase

Plotly convierte el topic map en un mapa interactivo con dos caras (HTML compartible y pestaña de la app) desde una sola función; el slider de granularidad es instantáneo porque solo repite la parte barata (HDBSCAN 2D), no la cara (UMAP). Paridad con la competencia: lograda; los diferenciadores grandes vienen en F4–F5.