

## Apunte 17 — El filtro de relevancia: el sistema se limpia solo

Proyecto Froth · aprender Machine Learning construyendo

### 1 El problema que TÚ detectaste

Validando el mapa (paso 3.7) viste un cluster etiquetado “*women, men, commodity, masculinities*”. Diagnóstico: los papers infiltrados de la Fase 1 (poesía, telecomunicaciones, historia — colisiones de siglas en las búsquedas) dominaban las keywords de un cluster que también contenía papers legítimos de economía del litio. La causa raíz estaba en el *pull*, no en el mapa.

### 2 La solución elegante: medir cada paper contra el TOPIC

Concepto: score de relevancia

Ya tenemos todas las piezas: cada paper tiene su vector, y el **título de tu tesis** también puede tenerlo. Entonces: *relevancia de un paper* = similitud coseno entre su vector y el vector del TOPIC. Un paper de poesía queda lejos del título de una tesis de flotación → score bajo → fuera. El sistema usa **sus propios embeddings para limpiarse a sí mismo** — cero reglas manuales, cero listas negras.

Concepto: el umbral lo dictan los datos, no la intuición

¿Dónde cortar? Miramos la distribución real de los 126 scores:

Infiltrados (poesía, telecom, historia...) 0.495 – 0.543

— **hueco natural** —

Todo lo legítimo (incluida economía del Li) 0.587 – 0.90

Hay un **hueco** entre 0.543 y 0.587: el umbral `RELEVANCE_THRESHOLD = 0.55` cae en medio y separa perfecto. Así se eligen umbrales en serio: mirando dónde los datos ya están separados, no inventando un número bonito.

### 3 Dónde vive en el código

- `embed.py` → `relevance_to_topic()`: calcula los scores y los guarda como columna `relevance` en `papers.parquet`.
- `config.py` → `RELEVANCE_THRESHOLD = 0.55` (con el razonamiento comentado).
- `cluster.py` → filtra ANTES de UMAP: la basura ni siquiera participa en el acomodo, así el mapa entero mejora.

### 4 Qué cambió en el mapa (iteración real de data science)

- Las etiquetas vergonzosas desaparecieron; el cluster de economía ahora es honesto (*usgs, old scrap* = reciclaje/commodities).
- Emergió un **4º cluster** que estaba enterrado: literatura **en francés** sobre recuperación de Nb-Ta-Sn — probablemente la escuela francesa que estudia Beauvoir. Hallazgo valioso... y lección nueva: *el idioma también agrupa* (SPECTER junta los papers franceses). Refinamiento futuro: ¿traducir abstracts o aceptar ese cluster como subtema válido?

- El ruido subió ( $9 \rightarrow 21$ ): al re-acomodarse el mapa, más papers quedaron entre nubes. Para eso está tu slider de granularidad.

#### Ojo / error típico

Así se ve el ciclo real del data science: **construir**  $\rightarrow$  **mirar**  $\rightarrow$  **detectar algo raro**  $\rightarrow$  **diagnosticar**  $\rightarrow$  **arreglar**  $\rightarrow$  **descubrir algo nuevo**. Tu ojo experto detectó el problema; los embeddings dieron la solución; y el arreglo destapó un hallazgo (el cluster francés) que nadie buscaba. Cada iteración enseña.

#### En una frase

Relevancia =  $\text{coseno}(\text{paper}, \text{TOPIC})$ ; umbral 0.55 elegido por el hueco natural en los datos; filtrado antes de UMAP. Resultado: mapa limpio, etiquetas honestas y un cluster francés sorpresa sobre Beauvoir. El sistema se limpia con sus propias herramientas.