

Apunte 20 — La red de similitud: K vecinos, umbral, y tus hubs y puentes reales

Proyecto Froth · aprender Machine Learning construyendo

1 Cómo se construyó la red

Cada paper se conecta con sus **K papers más parecidos** (similitud coseno calculada en el espacio **original de 768D** — no en el mapa 2D, que ya sabemos que distorsiona), y solo sobreviven las conexiones con similitud $\geq$ un **umbral**. Es el llamado *grafo kNN* (k nearest neighbors).

Concepto: las perillas K y umbral: nadie las “sabe”, se prueban

Preguntaste: ¿y quién dice que 5 vecinos es lo ideal? Respuesta honesta: **nadie** — es una perilla, como la granularidad. La forma seria de elegirla es probar valores y mirar la estructura resultante:

K	líneas	conex./paper	piezas	% entre clusters
3	281	4.7	1	17%
5	457	7.6	1	21%
8	702	11.7	1	24%
15	1213	20.2	1	30%

K alto revela más cruces entre temas (tus primeros vecinos son de tu familia; los lejanos cruzan fronteras) pero con 20 conexiones por paper el dibujo es ilegible (“bola de pelo”). Elegido: **K=5, umbral 0.75** — legible, con puentes visibles y la red en una sola pieza. Ambos viven en `config.py` (`GRAPH_KNN`, `GRAPH_SIM_THRESHOLD`): cambiar de opinión cuesta una línea.

2 Medir hubs y puentes (ya no a ojo)

Concepto: grado y betweenness

- **Hub** = nodo con muchas conexiones → se mide con el **grado** (contar sus aristas).
- **Puente** = nodo por el que pasan los caminos entre comunidades → se mide con la **betweenness centrality**: cuántas veces un nodo está en el camino más corto entre otros dos. Un paper con *pocas* conexiones puede ser un gran puente si esas pocas unen mundos.

3 Los resultados con TUS papers

Hubs (las lecturas obligatorias del corpus):

1. *The Magmatic–Hydrothermal Transition in Lithium Pegmatites* (24 conexiones)
2. *Electrostatically Controlled Enrichment of Lepidolite via Flotation* (15)
3. *Mineral Chemistry of Two-Mica Granite Rare Metals* (15)

Puentes (donde vive la novedad) — con dos hallazgos gordos:

1. Entre los 5 puentes top está “*Characterization and Liberation Study of the **Beauvoir Granite***”: el paper fundacional de TU yacimiento es un puente entre comunidades. La red

confirma **con números** que el territorio de tu tesis (geología $\leftrightarrow$ procesamiento en Beauvoir) es terreno-frontera: argumento de originalidad medible para tu introducción.

2. 3 de los 5 puentes top estaban etiquetados como **ruido** por HDBSCAN. La lección del Apunte 14 (“ruido $\neq$ basura; son generalistas entre nubes”) se cumplió cuantitativamente: *el ruido de ayer son los puentes de hoy.*

4 Dónde vive en el código

`froth/graph.py`: `build_similarity_graph()` (la red, con atributos por nodo), `find_hubs()` (grado), `find_bridges()` (betweenness), `save_graph()/load_graph()` (formato GraphML en `2_Datos/processed/`). Se corre con `python -m froth.graph`.

En una frase

Red kNN: cada paper con sus K=5 más parecidos (coseno en 768D), umbral 0.75 — perillas elegidas probando, guardadas en config. Grado encuentra hubs; betweenness encuentra puentes. Tu corpus confirmó: el paper de Beauvoir es un puente, y el “ruido” escondía a los puentes.