

Apunte 23 — DOI, open access y la lista de lectura

Proyecto Froth · aprender Machine Learning construyendo

1 La feature nueva: del ranking a la lectura

El buscador ya rankeaba papers; ahora además te lleva a **leerlos**: cada resultado trae dos enlaces, **DOI** (la página oficial del paper) y **open PDF** (el PDF gratuito, cuando existe). En tu corpus: **85 de 126 papers (67%) tienen PDF de acceso abierto** y 116/126 tienen DOI.

Concepto: DOI (Digital Object Identifier)

El **DOI** es el “número de cédula” permanente de un paper: 10.1016/j.... La URL [https://doi.org/\[DOI\]](https://doi.org/[DOI]) siempre lleva a la página oficial del editor, aunque la revista cambie de sitio web. Es la forma correcta de citar y de llegar al texto; si el paper es de pago, ahí usas tus accesos de universidad.

Concepto: open access (OA)

Un paper es **open access** cuando existe una copia legalmente gratuita: en la propia revista, en repositorios (arXiv, HAL...) o en la página de la universidad del autor. OpenAlex rastrea dónde está esa copia y nos da la URL (`oa_url`). Nosotros solo pedimos un campo más en el **select** del pull (`open_access`) — una línea de código, y el pipeline regeneró todo lo demás solo.

Ojo / error típico

Enlazar sí, descargar masivamente no. Froth te da el ENLACE y tú haces clic: la lectura ocurre de tu lado, con tus permisos. Descargar PDFs en masa desde editoriales viola sus términos de uso (riesgo previsto en el plan desde el día 1). Las herramientas serias (Connected Papers, etc.) hacen exactamente esto mismo: rankear + enlazar.

2 Bonus del día: el vigilante lento de Streamlit

La app tardaba mucho en arrancar y el log se llenaba de avisos de `torchvision`. Diagnóstico: el *file watcher* de Streamlit (auto-recarga al editar código) intenta examinar los cientos de módulos de `transformers`, uno por uno. Solución: apagarlo en `.streamlit/config.toml` (`fileWatcherType = "none"`). Lección doble: (1) un log ruidoso no siempre es un error fatal — hay que leer QUÉ dice; (2) las herramientas de desarrollo cómodas a veces cuestan rendimiento.

En una frase

Cada resultado del buscador ahora enlaza al DOI (página oficial) y al PDF open access cuando existe (67% de tu corpus). Enlazamos, no descargamos en masa. Y la app arranca más rápido tras apagar el file watcher de Streamlit.