

Apunte 24 — Qué es un gap (y cómo se mide de verdad)

Proyecto Froth · aprender Machine Learning construyendo

1 Por qué importan

Toda tesis debe aportar algo nuevo, y “nuevo” casi siempre significa **trabajar donde otros no han trabajado**. El problema: la frase “research gap” se usa mucho y se mide poco — suele ser una corazonada del supervisor. El diferenciador de Froth es convertir el gap en una **señal medible sobre los datos**, con evidencia que puedas citar.

2 Los 4 tipos de gap medibles

Concepto: 1. El SILO (el más valioso)

Dos comunidades que estudian cosas **muy parecidas** pero **no se citan**: trabajan de espaldas. Se mide restando dos matrices que ya tenemos: similitud semántica entre clusters (alta) vs. citas cruzadas (bajas). **Tu corpus lo tiene**: geología ↔ flotación = similitud 0.69 con **una sola cita cruzada** (Apunte 21). Dos mundos hablando del mismo granito sin hablarse. Quien conecte esos mundos, aporta.

Concepto: 2. La ZONA RALA

Regiones vacías del mapa *entre* nubes densas: combinaciones de temas que nadie tocó. Se mide con densidad espacial en el espacio de embeddings (¿cuántos papers viven entre el centroide de A y el de B?).

Concepto: 3. El PUENTE ESCASO

Entre dos clusters solo existen 1–2 papers puente (la betweenness del Apunte 20 concentrada en poquitos nodos). Si cruzar ese puente produce valor y casi nadie lo ha cruzado, hay sitio para más viajeros.

Concepto: 4. El TEMA DORMIDO

Un subtema cuyos papers son todos viejos: conocimiento que nadie revisita con métodos modernos. Se mide con la distribución de años por cluster (¿cuándo fue el último paper?).

3 La advertencia: mina o desierto

Ojo / error típico

Un hueco puede estar vacío por dos razones: porque **nadie lo exploró** (una mina esperando) o porque **no hay nada que encontrar** (un desierto — a veces la combinación de temas es estéril por buenas razones físicas o económicas). **Ningún algoritmo distingue una de otra.** Por eso Froth *propone candidatos con evidencia* y el experto decide. Desconfía de cualquier herramienta que prometa “gaps automáticos garantizados”; la nuestra promete candidatos honestos con sus números.

4 Tu tesis ya es la prueba del concepto

El título de la tesis (flotación de micas de Li **y su impacto en** la recuperación de by-products del granito de Beauvoir) explota *exactamente* el silo #1: une el cluster de flotación con el de geología. Fareed encontró ese gap a ojo y con experiencia; Froth lo encontró con números — similitud alta, una cita cruzada, y el paper de caracterización de Beauvoir como puente solitario (Apunte 20). Esa doble confirmación (experto + datos) es la validación más fuerte que puede tener el método.

5 Lo que viene (5.1)

Implementar las cuatro señales en `gaps.py` → `find_gaps()` devolverá una tabla rankeada: cada gap candidato con su tipo, su evidencia (similitud, citas, densidad, años) y los papers frontera que ya lo rondan. Después (5.2), el borrador de review citará esos gaps con números — no con corazonadas.

En una frase

Un gap medible tiene 4 formas: silos (parecidos que no se citan), zonas ralas, puentes escasos y temas dormidos. La herramienta propone candidatos con evidencia; el experto distingue minas de desiertos. Tu propia tesis es el silo geología-flotación de Beauvoir, ahora confirmado con números.