

Apunte 25 — De la teoría al texto: `find_gaps()` y el borrador de review

Proyecto Froth · aprender Machine Learning construyendo

1 Qué construimos (5.1 + 5.2)

Las dos mitades del diferenciador, ya funcionando en `froth/gaps.py`:

1. `find_gaps()`: convierte los 4 tipos del Apunte 24 en señales medidas → tabla rankeada con evidencia (`2_Datos/processed/gaps.parquet`).
2. `draft_review()`: redacta el andamio del literature review (`3_Resultados/review_draft.md`) con **citas 100% trazables**.

Se corren juntas: `python -m froth.gaps`.

2 Los gaps de TU corpus (resultados reales)

Tipo	Candidato top	Evidencia
Silo	commodities/críticos ↔ flotación	sim 0.69, 1 cita cruzada
Silo	flotación ↔ geología (<i>tu tesis</i>)	sim 0.70, 3 citas cruzadas
Puente escaso	commodities ↔ geología	solo 8 puentes pese a sim 0.67
Dormido	(ninguno: campo caliente, papers 2025-26)	la herramienta lo dice honesto

Lectura fina del silo campeón: la literatura de *criticidad/cadenas de suministro* y la de *procesamiento* casi no se citan. Conectarlas (“mi flotación importa para la seguridad de suministro de Li/Ta”) es munición directa para introducciones y propuestas.

Ojo / error típico

La señal más débil es la **zona rala**: mide *ausencias*, y un vacío no explica su porqué (¿mina o desierto?) — además de heredar las distorsiones del mapa 2D (Apunte 12). Por eso va etiquetada “experimental” en el código y en el draft. Regla general: desconfía más de las métricas sobre lo que falta que de las métricas sobre lo que existe.

3 El borrador: por qué una plantilla y no un LLM

Concepto: citas trazables o nada

El draft se genera con una **plantilla determinista**: cada sección nace de la estructura MEDIDA (secciones = clusters; imprescindibles = más citados + hubs locales; novedades = más recientes; huecos = gaps con sus números) y cada afirmación apunta a papers reales con referencia numerada [n] → lista final con autor/año/título/DOI. Un LLM redactaría más bonito... y tarde o temprano *inventaría* una referencia — el pecado capital académico. Orden correcto: primero el andamio confiable, después (opcional) un LLM que pula la prosa *verificando* cada cita contra el corpus.

4 Frente a la competencia (otro vecindario)

Aquí los rivales no son los mapeadores sino Elicit/SciSpace/Consensus (LLM que sintetiza *sin* conocer la estructura del corpus), Scholarcy (resúmenes 1-a-1) y ChatGPT a pelo (referencias alucinadas). **Nadie une mapa y texto:** nuestro draft dice “estos dos subtemas comparten 0.69 de similitud y una sola cita cruzada” porque lo midió. Límite honesto: trabajamos con abstracts (Elicit extrae del full text) → lo nuestro es un *andamio estructurado*, no prosa final.

En una frase

`find_gaps()` produce candidatos rankeados con evidencia (silos al frente: commodities-flotación 0.69/1 cita; tu tesis reconfirmada 0.70/3); `draft_review()` los convierte en un andamio de review con 26 referencias trazables, sin LLM. Nadie más une mapa y texto.