

Apunte 26 — El modo Tarea por dentro: trocear y promediar (mean pooling)

Proyecto Froth · aprender Machine Learning construyendo

1 El problema que no se ve

El modo Tarea acepta PDFs de instrucciones enteros. Pero SPECTER (como casi todos los modelos de embeddings) solo “lee” unos **512 tokens** ($\approx 350\text{--}400$ palabras): todo lo que pase de ahí lo **trunca en silencio**. Si le dieras un PDF de 10 páginas, el vector representaría... la primera página. El resto, ignorado sin aviso. Este tipo de límite silencioso es una trampa clásica de los modelos de lenguaje.

2 La solución: trocear y promediar

Concepto: chunking + mean pooling

`embed.embed_texts_mean()` hace dos pasos:

1. **Trocear (chunking)**: parte cada texto en pedazos de ~ 180 palabras (cómodamente bajo el límite).
2. **Promediar (mean pooling)**: vectoriza cada pedazo y calcula el **promedio** de todos los vectores $\rightarrow$ un solo vector que representa el documento COMPLETO.

La intuición geométrica: cada pedazo es un punto en el mapa del significado; el promedio es el *centro de gravedad* de todos — la posición media de lo que el documento trata.

Ojo / error típico

El promedio también *diluye*: si el PDF mezcla temas muy distintos, el centro de gravedad cae “entre” ellos y puede no representar bien a ninguno. Para instrucciones de tareas (temáticamente coherentes) funciona muy bien; para documentos-miscelánea habría que agrupar pedazos por tema primero. Limitación conocida y aceptada.

3 La prueba real

Consigna simulada: “*informe técnico comparando colectores para flotación de lepidolita y su selectividad frente a ganga de feldespato y cuarzo*” (repetida hasta forzar varios pedazos). Resultado: top-5 puros papers de colectores, encabezados por el del colector LCJ (similitud 0.897). El centro de gravedad cayó exactamente donde debía.

En una frase

Los modelos de embeddings truncan a ~ 512 tokens en silencio; el modo Tarea lo esquivo troceando el texto y promediando los vectores (mean pooling = centro de gravedad del significado). Probado: una consigna de colectores devuelve papers de colectores.