

Apunte 27 — Granularidad recomendada: que los datos elijan (DBCV)

Proyecto Froth · aprender Machine Learning construyendo

1 La pregunta de Batman que originó esto

“Quiero un botón de *ajustar a recomendado* con una razón estadística REAL — no un valor estándar, sino calculado cada vez.” Exactamente la actitud correcta: los defaults fijos son opiniones; los datos cambian con cada corpus.

2 La métrica correcta: DBCV

Concepto: DBCV (Density-Based Cluster Validity)

Para evaluar un clustering *por densidad* (HDBSCAN) no sirve cualquier métrica: la famosa *silhouette*, por ejemplo, asume clusters redondos y compactos. **DBCV** es la métrica nativa de la familia: premia clusterings cuyos grupos son **densos por dentro** y están **bien separados por fuera**, respetando formas irregulares. En código: `hdbscan.HDBSCAN(gen_min_span_tree=True).relative_validity_`.

Concepto: el barrido (sweep)

`cluster.recommend_min_cluster_size()` prueba TODAS las granularidades de 3 a 20, calcula la validez DBCV de cada una, descarta las degeneradas (1 solo cluster no es un clustering) y devuelve la ganadora + una tabla de diagnóstico. Con el corpus ampliado de hoy: recomendado = 7 (validez 0.51). Si mañana el corpus cambia, se recalcula solo (cacheado por versión de datos).

Ojo / error típico

La recomendación es un *óptimo estadístico*, no una verdad final: optimiza densidad y separación, no “qué historia le sirve al experto”. Por eso el slider sigue ahí — divagar está permitido y el botón siempre te trae de vuelta. Máquina propone; humano dispone (el patrón de todo Froth).

En una frase

El botón “Use recommended” no guarda un número mágico: barre granularidades y elige la que maximiza DBCV — la métrica de calidad nativa del clustering por densidad — recalculada para cada corpus. Estadística real, con el slider libre para explorar.