

## Apunte 28 — Conectores multi-fuente: tu cuenta institucional entra al juego

Proyecto Froth · aprender Machine Learning construyendo

### 1 Por qué no basta OpenAlex

OpenAlex es enorme (~250M trabajos) pero no lo tiene todo, y a veces le faltan abstracts. La idea de Batman: que el usuario **conecte sus propias cuentas** (estilo “Connect with Google”) y vea papers que la base gratuita no trae.

### 2 Los conectores (froth/sources.py)

| Fuente            | Requiere                                             | Qué aporta                       |
|-------------------|------------------------------------------------------|----------------------------------|
| OpenAlex          | nada (key opcional)                                  | la BASE: abstracts + referencias |
| Crossref          | solo un email                                        | metadatos masivos de editoriales |
| Semantic Scholar  | key GRATIS (opcional)                                | abstracts + PDFs open access     |
| Scopus (Elsevier) | key institucional                                    | el catálogo curado de Elsevier   |
| ResearchGate      | <b>NO</b> : sin API pública; su ToS prohíbe scraping |                                  |

Principios de diseño:

- **OpenAlex manda**: es el registro preferido (el más rico); los extras solo AÑADEN papers que no teníamos.
- **Dedup por DOI y luego por título** normalizado — el mismo paper llega por varias fuentes y debe contar una vez.
- **Fallo suave**: si una fuente está caída o te limita, avisa y el pull sigue con las demás. Nunca un conector tumba la cosecha.
- **Las keys son tuyas y locales**: viven en `.froth_keys` (gitignored). En la web pública vivirán solo en tu sesión de navegador — Froth jamás custodia keys ajenas en un servidor.

### 3 La primera cosecha multi-fuente (números reales)

- Crossref: 227 resultados crudos → el dedup reconoció **58 duplicados** de OpenAlex y aportó **169 nuevos** (tras el filtro de abstract: corpus 126 → **157**).
- Semantic Scholar sin key: rate-limit inmediato → **falló suave** tal como se diseñó (con la key gratuita queda estable).
- El corpus ampliado reveló un **subtema emergente**: física de burbujas/partículas finas (+ bastnäsita) — antes enterrado, ahora cluster propio. Más datos → más resolución del mapa.
- El filtro de relevancia solo descartó 6: la cosecha extra venía limpia — el auto-lavado del Apunte 17 escaló sin tocarlo.

## En una frase

sources.py suma Crossref/S2/Scopus a OpenAlex con dedup DOI→título y fallo suave; las keys son locales y del usuario (panel “Connect institutional account”). Primera cosecha: +31 papers netos y un subtema nuevo emergió. ResearchGate queda fuera por diseño (sin API legal).