

Apunte 30 — El nacimiento de specter-mineral: tu primer entrenamiento real

Proyecto Froth · aprender Machine Learning construyendo

1 Qué pasó (en 83 segundos)

Tu RTX 5060 tomó el SPECTER genérico y lo **afinó** con los $\sim 1,250$ pares título $\leftrightarrow$ abstract del corpus maestro: 2 épocas, 160 pasos, lotes de 16. El resultado vive en `models/specter-mineral` — un modelo de embeddings que habla el dialecto del procesamiento mineral. En CPU habrían sido horas; en tu GPU, 83 segundos.

2 Los conceptos que acabas de usar

Concepto: fine-tuning (afinar) $\neq$ entrenar desde cero

No construimos un modelo nuevo: tomamos los pesos de SPECTER (que ya sabe “leer papers”) y los **empujamos suavemente** hacia tu dominio. Como un geólogo generalista haciendo una especialización — no vuelve a la primaria.

Concepto: la jugada elegante: auto-supervisión con MNRL

Entrenar suele exigir etiquetas humanas (“estos dos textos son parecidos”). No etiquetamos NADA. El truco: **MultipleNegativesRankingLoss** — en cada lote de 16 papers, el título de un paper debe quedar más cerca de *su propio* abstract que de los otros 15 del lote. Positivos gratis (título y abstract del mismo paper hablan de lo mismo) y negativos gratis (los demás del lote). Un corpus plano se vuelve dataset de entrenamiento sin mover un dedo.

Concepto: el vocabulario del entrenamiento

- **loss (pérdida)**: el número que mide “qué tan equivocado va” el modelo; entrenar = empujar los pesos para bajarlo.
- **paso (step)**: procesar un lote y ajustar pesos una vez. Viste “160 pasos”.
- **época (epoch)**: una pasada completa por todo el dataset. Hicimos 2.
- **warmup**: los primeros pasos con ajustes suavecitos, para no desbaratar lo que el modelo ya sabía.
- **mixed precision (amp)**: cuentas en números de menor precisión donde no importa — el motivo de parte de la velocidad en GPU.

Ojo / error típico

Los tropiezos también enseñan: el entrenamiento falló DOS veces antes de arrancar — faltaban `datasets` y luego `accelerate` (el kit del Trainer de Hugging Face). Lección de ecosistema: en ML moderno “instalar la librería” rara vez basta; el stack de entrenamiento es su propia bestia. Ambas quedaron en `requirements.txt` para siempre. Y antes de eso: pip se negó a cambiar torch CPU $\rightarrow$ CUDA porque “la versión ya estaba satisfecha” (mismo número, distinta variante) — se resolvió con `--force-reinstall --no-deps`.

3 Cómo se juzga si valió la pena (6.6)

Un modelo nuevo no es mejor por existir. `froth/compare.py` somete a AMBOS modelos al mismo examen sobre los 22 topics: mismos corpus, mismo UMAP (semilla fija), granularidad elegida por DBCV — ¿quién produce clusters más válidos? Además exporta un **test ciego**: dos listados de clusters A/B con la clave escondida, para que el experto (tú) juzgue sin saber quién es quién. Si specter-mineral no gana, eso TAMBIÉN es un resultado honesto y publicable.

En una frase

Fine-tuning = empujar pesos existentes hacia tu dominio; MNRL convierte el corpus en dataset sin etiquetar (tu título debe amar a tu abstract más que a los ajenos); 83s en tu GPU tras dos tropiezos de dependencias. El veredicto lo dan DBCV en 22 topics y tu test ciego — no el entusiasmo.