

Apunte 35 — La frase centroide: el filtro de relevancia al revés

Proyecto Froth · aprender Machine Learning construyendo

1 La idea (ya la conocías sin saberlo)

En la Fase 3, el filtro de relevancia medía el coseno de cada paper contra el vector del TOPIC y *descartaba* lo lejano. La frase centroide usa la MISMA matemática con la intención opuesta: medir el coseno de cada frase contra el centro del cluster y *coronar* lo más cercano.

Concepto: centroide y frase representativa

El **centroide** de un cluster es el promedio de los vectores (768D) de sus papers: su “centro de masa semántico”. Las frases de los abstracts se vectorizan con el MISMO modelo (SPECTER), así que viven en el mismo espacio y son comparables. La frase con mayor coseno al centroide es la que mejor resume de qué va el subtema — elegida por geometría, no por opinión.

2 Los resultados reales (corpus Beauvoir, 237 papers)

`python -m froth.review` sobre tus datos:

- Cluster geología (“ma, melt, compositions”): score **0.947** para “*LCT-type granitic pegmatites represent a major global source of lithium...*” — una definición de libro del subtema.
- Cluster USGS (“usgs, old scrap, year”): “*Minerals Yearbook — These annual publications review the mineral industries of the United States...*” Las keywords jamás te dijeron que ese cluster son INFORMES ANUALES; la frase sí.
- Cluster flotación de lepidolita: “*Efficient flotation of lepidolite is crucial for the extraction and recycling of lithium resources...*”

Esto resuelve tu pedido de títulos con sentido (7.1b): keywords para clasificar, **frase centroide como subtítulo** para entender.

3 Dos guardas contra trampas

- **Tope por paper** (`per_paper_cap=2`): sin él, un abstract muy “central” podría monopolizar el resumen entero del cluster.
- El centroide se calcula sobre los vectores de PAPER (los del mapa), no sobre las frases: así el resumen es fiel al mismo espacio que el usuario está viendo.

Ojo / error típico

Las frases top se parecen al centroide... y por eso se parecen ENTRE SÍ: el ranking por centroide tiende a la redundancia (tres frases diciendo lo mismo). Ese es exactamente el problema que ataca MMR en la sub-fase 7.3.

En una frase

Frase centroide = $\cos(\text{frase}, \text{centro del cluster})$, misma matemática que el filtro de relevancia pero para coronar en vez de descartar. En Beauvoir produce definiciones de libro con scores 0.92-0.95. Su debilidad (redundancia) la corrige MMR (7.3).