

Apunte 36 — TextRank: PageRank sobre frases (el hub de las frases)

Proyecto Froth · aprender Machine Learning construyendo

1 La idea: reciclar el algoritmo de Google

PageRank ordenaba la web con una idea circular pero resoluble: *una página importa si páginas importantes la enlazan*. TextRank (Mihalcea & Tarau, 2004) cambia páginas por frases y enlaces por similitud: *una frase importa si frases importantes se le parecen*. Es EXACTAMENTE tu concepto de hub de la Fase 4, aplicado dentro de cada cluster.

Concepto: el grafo de frases y el paseo aleatorio

Nodos = las frases del cluster; peso de la arista = coseno entre sus vectores SPECTER. PageRank se calcula con **iteración de potencias**: imagina un lector saltando de frase en frase, prefiriendo saltos hacia frases similares; con probabilidad $1 - d$ ($d = 0.85$) se teletransporta a cualquiera. Tras iterar

$$r \leftarrow \frac{1 - d}{N} + dWr$$

unas 50 veces, r converge: el tiempo que el lector pasa en cada frase ES su importancia. En `froth/review.py` son 4 líneas de numpy — sin librerías nuevas.

2 Centroide vs TextRank: no miden lo mismo

- **Centroide** premia lo *típico*: la frase más parecida al promedio.
- **TextRank** premia lo *respaldado*: la frase con más “votos” de consenso, aunque el consenso venga de un subgrupo denso.

En tu corpus (¡corre `python -m froth.review` y júzgalo!):

- Cluster USGS: AMBOS eligen “Minerals Yearbook — These annual publications review...” — cuando dos métricas independientes coinciden, esa frase ES el tema.
- Cluster lepidolita: TextRank prefirió “...the lepidolite flotation process and its challenges are summarized, including poor selectivity...” — frases de REVIEW (resumen los retos del campo) reciben muchos votos porque tocan a todas. Para un literature review, eso es una virtud.
- Cluster geología: TextRank se fue a depósitos exógenos — un subgrupo denso de frases mineralógicas se vota entre sí y captura el ranking. El centroide, anclado a los vectores de los PAPERS, resiste mejor esa trampa.

Ojo / error típico

Los scores no son comparables entre métodos: el coseno vive en 0–1; PageRank reparte una probabilidad total de 1 entre N frases (por eso ves 0.008). Compara RANKINGS, no números. Y ninguno de los dos evita la redundancia — eso es MMR (7.3).

En una frase

TextRank = PageRank sobre el grafo de similitud de frases, resuelto por iteración de potencias. Premia el consenso (bueno para frases-resumen), pero un subgrupo denso puede capturarlo; el centroide premia lo típico. El experto decide cuál lee mejor — o se combinan.