

Apunte 37 — MMR: relevante pero distinto (y un objetivo que salió degenerado)

Proyecto Froth · aprender Machine Learning construyendo

1 El problema que quedaba

El centroide (apunte 35) tiene un defecto estructural: las frases que se parecen al centro se parecen ENTRE SÍ. En tu cluster de geología, las 3 mejores frases tenían similitud mutua de **0.945** — un resumen diciendo lo mismo tres veces.

Concepto: Maximal Marginal Relevance (Carbonell & Goldstein, 1998)

Selección voraz, una frase a la vez. Cada candidata se puntúa como

$$\lambda \cdot \text{relevancia} - (1 - \lambda) \cdot \text{redundancia}$$

donde redundancia = su similitud máxima con lo YA elegido. Con $\lambda = 1$ vuelves al centroide puro; bajando λ compras diversidad pagando relevancia. La primera elegida siempre es la más relevante (no hay nada elegido aún con qué ser redundante).

2 El tropiezo (que enseña más que el acierto)

Primer intento de elegir λ con datos: “maximizar relevancia – redundancia”. Resultado: recomendó $\lambda = 0.5$... el BORDE de la grilla. Ese objetivo es **degenerado**: bajar λ SIEMPRE reduce la redundancia más rápido de lo que pierde relevancia, así que el “óptimo” se escapa hacia abajo indefinidamente. Un recomendador que siempre elige el extremo no está midiendo nada.

3 La regla que sí funciona

Mirando tu barrida real (corpus Beauvoir, 12 clusters):

λ	relevancia	redundancia
0.5	0.868	0.758
0.6	0.906	0.829
0.7	0.918	0.860
0.8	0.921	0.873
1.0	0.923	0.884

De 1.0 a 0.7 la relevancia casi no cae (−0.5%) y la diversidad llega gratis; de 0.7 hacia abajo empiezas a pagar de verdad. Regla adoptada (interpretable): **el λ más diverso que conserve $\geq 99\%$ de la relevancia alcanzable**. Tu corpus votó $\lambda = 0.7$ solo — y coincide con el default de la literatura, pero ahora SABEMOS por qué vale para estos datos (regla 9 del proyecto).

Pruébalo tú (teclado en mano)

```
.venv\Scripts\python.exe -m froth.review — al final imprime la barrida y el
antes/después del cluster más redundante: el centroide da 3 frases clónicas de pegmatitas;
MMR mantiene la definición y añade granitos Nb-Ta y el Erzgebirge. Tres ángulos, no un
eco.
```

Ojo / error típico

MMR es voraz: elige lo mejor AHORA sin mirar adelante, porque el óptimo exacto es combinatorio (probar todas las combinaciones de frases). Para resúmenes de 3-5 frases, la aproximación voraz es el estándar y sobra.

En una frase

$MMR = \lambda \cdot \text{relevancia} - (1 - \lambda) \cdot \text{redundancia}$, selección voraz. El primer objetivo para elegir λ salió degenerado (se clavó al borde); la regla final — máxima diversidad conservando el 99% de la relevancia — eligió 0.7 con tus datos. Con esto están las 3 piezas del ranking: típico (centroide), respaldado (TextRank) y diverso (MMR). Sigue ensamblar el draft v2 (7.4).