

Apunte 38 — El draft v2: mezclar jueces con Borda y citar por construcción

Proyecto Froth · aprender Machine Learning construyendo

1 Ensamblar sin inventar

`draft_review_v2()` junta las tres piezas (apuntes 35-37) en un borrador por cluster: una frase ABRE (panorama), 2 frases RESPALDAN (típicas pero diversas), y cada una lleva su cita $[n]$ apuntando al paper del que salió textual. La numeración es global y por orden de aparición; el mismo motor emite el `.bib` para LaTeX/Zotero. Nada se genera: nada puede alucinarse.

2 El problema del opener y la solución de Borda

El plan era “TextRank abre” (sus frases-panorama son ideales). Pero en geología abrió con la frase de depósitos exógenos — la captura por subgrupo denso del apunte 36. Los scores de centroide (coseno 0-1) y TextRank (probabilidad repartida) NO son comparables, así que no se pueden promediar... pero los *rankings* sí.

Concepto: conteo de Borda (1770, elecciones; hoy, rank aggregation)

Cada método ordena las frases y la posición es el “voto”: $1^{\circ} = 0$ puntos, $2^{\circ} = 1$, etc. Gana la frase con MENOR suma de posiciones. Para secuestrar el opener habría que engañar a los DOS jueces a la vez: el subgrupo denso pierde porque el centroide rankea bajas sus frases. Con tus datos: geología pasó de exógenos a composición química de pegmatitas; lepidolita conservó su apertura panorámica.

3 Fidelidad: rechazar, no recortar

El primer draft abrió lepidolita con “*In addition, ...*” — un conector que apunta a texto inexistente. Dos arreglos posibles: RECORTAR el conector (modifica la cita textual: prohibido por la regla de fidelidad del proyecto) o RECHAZAR la frase y dejar que Borda promueva la siguiente. Se rechaza: el filtro `_self_contained()` ahora también veta conectores de discurso de dos palabras (“In addition”, “On the other hand”, “In contrast”...). La siguiente elegida fue “*Efficient flotation of lepidolite is crucial...*” — mejor apertura, cero manipulación del original.

Ojo / error típico

El $\dagger$ del draft marca frases donde centroide y TextRank coinciden en el top-3 (consenso = sello de confianza). Si una sección no tiene $\dagger$, no está mal — solo significa que los dos jueces vieron virtudes distintas.

Pruébalo tú (teclado en mano)

```
.venv\Scripts\python.exe -m froth.review genera 3_Resultados/review_draft_v2.md
```

(42 refs trazables en Beauvoir) y su `.bib`. Abre el `.md` y verifica una cita: busca el $[n]$, ve a References, y comprueba que la frase existe en el abstract de ese paper. Trazabilidad auditable.

En una frase

Draft v2 = Borda elige el opener (engañar a dos jueces es más difícil que a uno), MMR pone el respaldo diverso, cada frase va textual con cita [n] + BibTeX. Frases con conectores colgantes se RECHAZAN (nunca se recortan): la fidelidad manda.