

Apunte 39 — El LLM como pulidor verificado (nunca como autor)

Proyecto Froth · aprender Machine Learning construyendo

1 La jerarquía de confianza

El draft v2 es extractivo: verdad garantizada, prosa regular. Un LLM escribe prosa excelente... sin garantía de verdad. La arquitectura de la fase 7.6 saca lo mejor de ambos SIN heredar el riesgo:

Concepto: pulir $\neq$ generar

El LLM local (Ollama) recibe UNA instrucción estrecha: reescribir el párrafo de una sección para que fluya, sin añadir ni quitar afirmaciones, manteniendo cada cita $[n]$ exactamente una vez. No investiga, no opina, no cita: PULE frases que ya existen. El conocimiento viene del corpus; el LLM solo aporta gramática.

2 La puerta de verificación (el corazón del diseño)

Confiar no basta: cada sección reescrita pasa por `_verified()` en `froth/polish.py`:

- **Censo de citas**: las citas $[n]$ del texto pulido deben ser EXACTAMENTE las del original (ni una menos = borró evidencia; ni una más = inventó).
- **Banda de longitud** ($0.5\text{--}1.7\times$): fuera de ahí, o resumió de más (perdió afirmaciones) o divagó (probablemente añadió).
- Si CUALQUIER chequeo falla $\rightarrow$ la sección conserva su original extractivo, en silencio. El draft solo puede mejorar, jamás mentir.

Probado sin servidor: la puerta rechazó cita borrada, cita inventada y texto encogido; y sin Ollama corriendo el draft queda intacto (fallo suave, como los conectores de fuentes).

3 Por qué LOCAL (Ollama) y no una API

Decisión tuya de la Fase 6 que aquí paga: gratis (sin cuotas), privado (tu review no sale de tu PC), offline, y diferenciador — Elicit/SciSpace/Consensus dependen de OpenAI. Tu RTX 5060 corre un modelo 8B cómodamente. Setup en `docs/OLLAMA_SETUP.md` (un instalador + `ollama pull llama3.1:8b`, ~ 5 GB, una sola vez).

Ojo / error típico

Temperatura 0.2 (casi determinista): para pulir no quieres creatividad, quieres obediencia. Y el pulido es una DESCARGA SEPARADA — el extractivo sigue siendo el default visible. La cadena de confianza: mapa medido $\rightarrow$ frases reales $\rightarrow$ prosa pulida verificada. Cada eslabón auditable.

En una frase

El LLM local reescribe párrafos ya contruidos y una puerta automática (censo de citas + banda de longitud) descarta cualquier reescritura sospechosa, sección por sección. Prosa de LLM con la trazabilidad del extractivo — o nada.