

Apunte 40 — Títulos de cluster con sentido: KeyBERT (no oraciones recortadas)

Proyecto Froth · aprender Machine Learning construyendo

1 El problema (lo viste tú)

La v1 de los subtítulos tomaba la *oración* más central del cluster y la cortaba a 12 palabras. Resultado: encabezados como “Considering both...”, “In the present st...” — fragmentos que insinúan el tema pero se sienten recortados, como una biblia a medio leer. Y las keywords viejas (c-TF-IDF: “dpa, dda, lepidolite”) tampoco: clasifican bien pero *no comunican*.

2 Cómo lo resuelve el campo: KeyBERT

El estándar (KeyBERT, y la capa de representación de BERTopic) no recorta oraciones: extrae **keyphrases** cortas y las rankea por SIGNIFICADO.

Concepto: KeyBERTInspired en 3 pasos

1. **Candidatos:** n-gramas de 2–3 palabras del texto del cluster (con el mismo vectorizador endurecido de `cluster.py`: sin dígitos, elementos químicos salvados).
2. **Ranear:** embeber cada candidato con SPECTER y medir su coseno al *centroide* del cluster.
3. **Diversificar:** MMR para que las frases elegidas no sean casi iguales.

Lo elegante: son las MISMAS piezas que Froth ya tenía (SPECTER + coseno + centroide + MMR de la Fase 7). Por eso se hizo a mano, sin dependencia nueva — el patrón del proyecto: construir cada pieza para entenderla.

3 Dos tropiezos que enseñan (tus datos reales)

El primer intento sacó títulos con ruido de OCR (“limu”, “nmic”, “cgfs”) y genéricos (“ore flotation” donde debía decir “lepidolite flotation”). Dos arreglos:

- **min_df $\geq$ 2:** exigir que la frase aparezca en VARIOS papers del cluster. La basura de OCR vive en un solo abstract $\rightarrow$ fuera.
- **Score contrastivo** (la idea de c-TF-IDF, pero en el espacio de embeddings):

$$\text{score} = \cos(\text{frase}, \text{centroide}_c) - 0.4 \cos(\text{frase}, \text{centroide}_{\text{global}})$$

Premia lo que está cerca de ESTE cluster y lejos del corpus entero. Así “lepidolite flotation” (específico) le gana a “ore flotation” (genérico, cerca del centro de todo).

Ojo / error típico

El keyphrase más cercano al centroide NO es el mejor título: suele ser el más genérico. La especificidad (lejos del promedio global) es lo que hace que un título *diga* algo. Misma lección que el h-index y el filtro de relevancia: la señal está en el contraste, no en el valor absoluto.

Pruébalo tú (teclado en mano)

El título corto va al encabezado; la oración centroe completa se guarda en la columna **summary** y aparece en el **hover** — corto arriba, detalle al pasar el mouse, justo como lo pediste.

En una frase

Títulos de cluster = keyphrases de 2–3 palabras extraídas por KeyBERT (candidatos + SPECTER + coseno al centroe + MMR), con `min_df` contra el ruido y un score contrastivo (cluster – global) para preferir lo específico. Cortos, con sentido, sin recortar oraciones; la frase completa vive en el hover.