

Apunte 41 — El veredicto del re-fine-tune: más datos NO mejoró

Proyecto Froth · aprender Machine Learning construyendo

1 La hipótesis (tu duda del learning log)

El fine-tune v1 (specter-mineral, 1.290 papers) ganaba 14/22 en DBCV pero castigaba la periferia (hasta -0.43). Hipótesis natural: con **3× más datos** (re-cosecha con keys $\rightarrow$ 4.045 papers) el modelo v2 debería generalizar mejor y dejar de penalizar los topics lejanos. Lo pusimos a prueba, medido.

2 El experimento limpio

Entrenamos v2 (4.045 pares título $\leftrightarrow$ abstract, MNRL, 249s en tu RTX 5060) y comparamos **los tres modelos sobre los MISMOS 22 corpus nuevos** por DBCV: base (SPECTER genérico), v1 (fine-tune viejo) y v2 (fine-tune grande).

	gana a base	delta medio
v1 (1.290 papers)	16/22	+0.093
v2 (4.045 papers)	14/22	+0.069
v2 vs v1 directo	10/22	-0.024

Concepto: el resultado: escalar datos NO ayudó (y hasta empeoró un poco)

v2 gana a base MENOS veces que v1 (14 vs 16) y con menor margen. Cabeza a cabeza, v2 le gana a v1 en solo 10/22 con delta medio negativo. **El fine-tune pequeño y curado fue igual o mejor que el grande.**

3 Por qué (la lección de verdad)

La re-cosecha 3× trajo más papers, pero también más DIVERSOS y RUIDOSOS (colisiones de términos multi-dominio como “attrition”/“autogenous”, más subdominios). El fine-tuning auto-supervisado arrastra el modelo hacia el *centro de masa* del corpus de entrenamiento (apunte 31); al agrandar el corpus con ruido, ese centro se mueve hacia lo genérico y la especialización se DILUYE.

Ojo / error típico

En fine-tuning auto-supervisado, la CALIDAD y coherencia del corpus importa más que la cantidad. “Más datos” es un reflejo, no una ley. La varianza sigue altísima: v2 va de $+0.47$ (escorias XCT) a -0.51 (finos de silicato de hierro) — el fine-tune es una apuesta por-topic, no una mejora uniforme.

4 Qué queda en producción

Nada cambia: producción sigue con el SPECTER **base** (el más estable across topics). Los fine-tunes son el RESULTADO DE INVESTIGACIÓN. v1 se conserva (models/specter-mineral-v1); v2 queda como referencia. Evidencia completa en 2_Datos/model_comparison_3way.csv.

En una frase

Re-fine-tune con $3\times$ datos: v2 gana a base 14/22 (v1 ganaba 16/22), y pierde contra v1 cabeza a cabeza (delta medio -0.024). Más datos NO mejoró — el corpus grande y ruidoso diluyó la especialización. Lección de tesis honesta: en fine-tuning auto-supervisado, la curación del corpus $>$ el tamaño. “No mejora” también es resultado.