

Apunte 43 — La puerta de relevancia: separar el grano de la paja en 190.000 papers

Proyecto Froth · aprender Machine Learning construyendo

1 Glosario en palabras simples (léelo primero)

- **Vector:** la “huella digital” numérica de un paper — una lista de 768 números que captura su significado. Papers que hablan de lo mismo tienen huellas parecidas (apunte 05).
- **Coseno:** el medidor de parecido entre dos huellas. Va de -1 a 1 : cerca de 1 = hablan de lo mismo; cerca de 0 = nada que ver.
- **Centroide:** el “promedio” de un grupo de vectores — su centro de gravedad, como la ley media de un lote de mineral.
- **Umbral:** el valor de corte. Encima: el paper entra al mapa. Debajo: fuera.
- **Bimodal:** distribución con DOS jorobas. Si los buenos hacen una y los malos otra, el valle entre ambas es el corte natural.
- **Hub / cluster:** grupo de papers muy parecidos entre sí — un subtema.

2 El problema que TÚ encontraste

Con la cosecha sin techo (190.000 papers), abriste el mapa de tailings y viste “*cosas hasta de recursos humanos, en colores*”. Tu hipótesis fue exacta: ninguna palabra falló al vectorizarse — falló **la puerta** que decide qué entra al mapa.

La puerta vieja: relevancia = $\cos(\text{paper}, \text{TÍTULO del topic})$, con umbral fijo 0.55. Medido en tailings: aceptaba el **93%** de 16.681 papers, incluyendo clamidiosis en koalas (por “iron” biológico), “event management” (por “management”) y “Circular Economy in SMEs” (por “circular economy”). Una frase corta con imanes genéricos no puede distinguir facetas. Además, el techo viejo de 25 resultados por término era un filtro de precisión ACCIDENTAL: al quitarlo (decisión correcta: cobertura es la misión), entró la cola profunda de cada término.

3 Mini-ejemplo de juguete (haz las cuentas conmigo)

Huellas de solo 2 números (en vez de 768). El título apunta a $T = (1, 0)$. Tres papers:

	vector	cos con el título
A: flotación de relaves	(0.98, 0.20)	0.98
B: gestión de personal	(0.60, 0.80)	0.60
C: koalas	(0.50, 0.87)	0.50

Con umbral 0.55, ¡B entra al mapa! ($0.60 > 0.55$). Ese es tu hub de recursos humanos.

La **puerta contrastiva** pregunta algo mejor: ¿te pareces a mi tema MÁS de lo que te pareces a lo genérico?

$$v_2 = \cos(\text{paper}, \text{núcleo}) - 0.4 \cdot \cos(\text{paper}, \text{global})$$

donde núcleo $\approx A$ (los papers más pegados al título) y global = promedio de todos $\approx (0.74, 0.67)$ normalizado. Cuentas:

$$v_2(A) = 1.00 - 0.4 \cdot 0.86 = \mathbf{0.66} \quad v_2(B) = 0.75 - 0.4 \cdot 0.98 = \mathbf{0.36}$$

B queda lejos de cualquier corte razonable. Con 768 números y 16.681 papers, esto mismo produjo una distribución **bimodal** con valle en $+0.399$ — y el umbral se elige en ESE valle, por corpus (perilla calculada, no constante fósil).

Concepto: la idea contrastiva

Es el mismo truco que arregló los títulos KeyBERT (apunte 40): premiar cercanía al núcleo Y castigar cercanía a la masa genérica. Lo genérico compartido deja de contar como mérito.

4 Tropiezo 1: la puerta por-paper aplanó los mapas

La primera versión juzgaba paper por paper... y tailings pasó de 115 subtemas a **2** (a CUALQUIER granularidad — lo confirmó el barrido DBCV). ¿Por qué? Al quedarte solo con “los parecidos al núcleo”, la población superviviente es una banda homogénea: una bola sin valles internos que HDBSCAN no puede subdividir. Ganamos precisión, destruimos la ESTRUCTURA — que es la mitad del producto.

El arreglo salió de tu propia frase (“un hub de RRHH, *en colores*”): la basura llega en **hubs coherentes**, así que la puerta debe juzgar HUBS: (1) mapear TODO, (2) puntuar cada cluster por el v_2 promedio de sus miembros, (3) botar clusters enteros bajo el valle de esas medias, (4) el ruido suelto se juzga individual. Medido: los hubs de física de partículas, astronomía, RRHH y koalas murieron completos; el de morteros con relaves no perdió ni un paper; 325 subtemas del dominio intactos.

5 Tropiezo 2: tu doble ciego destapó un sesgo

Juzgaste 40 casos de frontera a ciegas: 62% de acuerdo, pero con dirección — rescataste 11 papers que la máquina botaba, casi todos de **economía circular**... que está EN el título de tu tesis. Causa: el centro global apunta en parte hacia el propio tema (el corpus está lleno de él), así que un paper alineado con el título recibía premio del núcleo Y castigo del global: doble penalización por su propia identidad. Arreglo: **proyectar fuera** del global la dirección del núcleo antes de castigar. Verificado: “Towards Circular Economy Metrics” volvió; koalas y el paper del queso (“Iron Ages”... de la Edad del Hierro, no del mineral) siguen fuera.

Honestidad de cierre: re-medido tu acuerdo contra la puerta final, quedó en 60% — prácticamente igual. El fix ganó los casos que te importaban (los de economía circular), pero la frontera de ± 0.04 del valle es ambigua HASTA para el experto (tú dejaste pasar el queso por el “Iron”). No se afina más: sería sobreajustar a 40 casos.

Ojo / error típico

El valor del gate está en el nivel de HUBS (basura coherente muere entera, estructura del dominio intacta), no en decorar el borde. Ninguna frontera unidimensional es perfecta; el flujo correcto es máquina propone $\rightarrow$ experto valida $\rightarrow$ la perilla se recalibra donde el experto tiene razón sistemática (economía circular sí, queso no).

En una frase

Puerta vieja: cos con el título + umbral fijo = 93% aceptado, koalas en colores. Puerta nueva: score contrastivo (núcleo vs. global SIN la dirección del tema) → bimodal → valle POR corpus → juicio por HUBS para preservar estructura. Resultado: 22/22 topics limpios con su propio umbral, master de 77.636 papers únicos relevantes. Tres lecciones: (1) contrastar contra lo genérico separa lo que el parecido a secas no puede; (2) filtrar individuos puede destruir la estructura colectiva — juzga al grupo cuando la señal es grupal; (3) el juez humano encuentra los sesgos que la métrica no ve — y también tiene los suyos.